Modelo de Poisson -> A variável dependente limitada é representa por uma variável de contagem, ou seja, os valores de y não são negativos e discretos por construção. Exemplo: número de filhos por mulher, não ter = 0, ter um = 1, ter dois = 2 e assim por diante.

-> Diferente dos modelos probit (distribuição normal) e logit (distribuição logística) não temos uma dummy, mas uma variável de contagem, usamos uma distribuição de poisson por esse fato, isso significa que todos os seus momentos são determinados inteiramente pela média, ou seja, segue a hipótese -> $E(y|x) = Var(y|x)$

-> Estimação = Ela acontece por meio do estimador de máxima verossimilhança, que encontra os betas que maximizam a probabilidade de encontrar sua amostra no modelo descrito. O estimador de MQO será viesado, apresentando muitas vezes previsão negativa de y e heterocedasticidade.

-> Etapas de estimação

1) monto a função de verossimilhança
2) aplico o logaritimo

-> Interpretação = Há duas formas de interpretação, a simplificada, onde eu posso interpretar os Bs diretamente como uma semi-elasticidade, porque eu considero o log da média condicional, sendo explicado pelas variáveis no nível e a outra por meio do efeito marginal

* Exemplo:

→ análise simplificada

$\% \Delta E(y|x) \approx 0,1 \times \hat{\beta}_J$ → intercepto estimado

↳ 10%

pcnv → número esperado de prisões

$-0,402 \times 0,1 = -4\%$, a cada aumento de 10% na probabilidade de condenação, o número esperado de prisões cai 4%

→ efeito marginal (Stata: margins dy dx)

$\exp(\hat{\beta}_K) - 1$

$2,718^{0,661} - 1 = 93,67\%$

Determinants of Number of Arrests for Young Men

Dependent Variable: *narr86*		
Independent Variables	**Linear (OLS)**	**Exponential (Poisson QMLE)**
pcnv	−.132 (.040)	−.402 (.085)
avgsen	−.011 (.012)	−.024 (.020)
tottime	.012 (.009)	.024 (.015)
ptime86	−.041 (.009)	−.099 (.021)
qemp86	−.051 (.014)	−.038 (.029)
inc86	−.0015 (.0003)	−.0081 (.0010)
black	.327 (.045)	.661 (.074)
hispan	.194 (.040)	.500 (.074)
born60	−.022 (.033)	−.051 (.064)
constant	.577 (.038)	−.600 (.067)
Log-likelihood value *R*-squared $\hat{\sigma}$	— .073 .829	−2,248.76 .077 1.232